从数据迷雾到智能洞察：驾驭Elastic机器学习

利用 Anomaly Detection 与 Data Frame Analytics 探索数据新维度



传统监控的极限



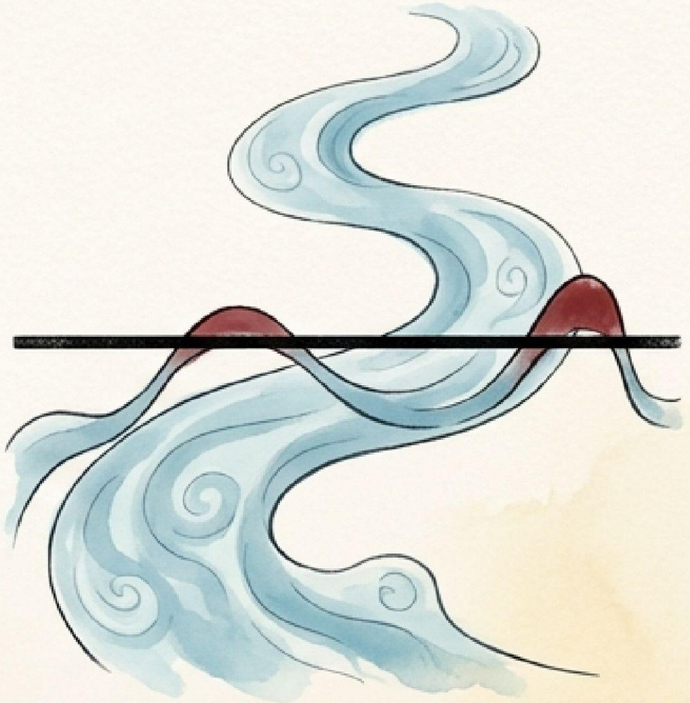
搜索（Search）

只能找到你已知的问题。



仪表盘（Dashboards）

被动观察，需要持续的人工关注，难以聚焦。

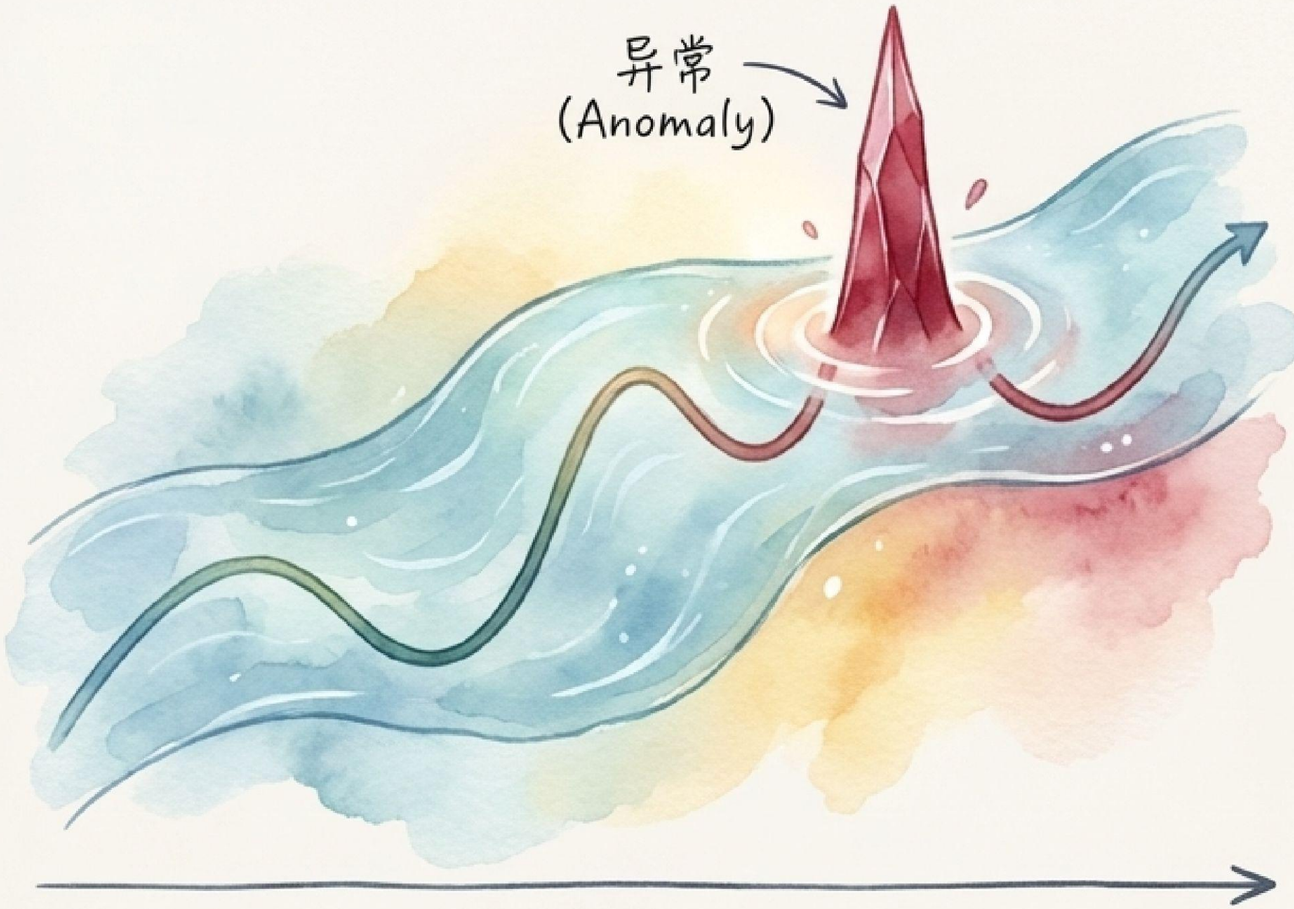


静态阈值（Static Thresholds）

“新常态”就是持续变化，静态规则无法适应。

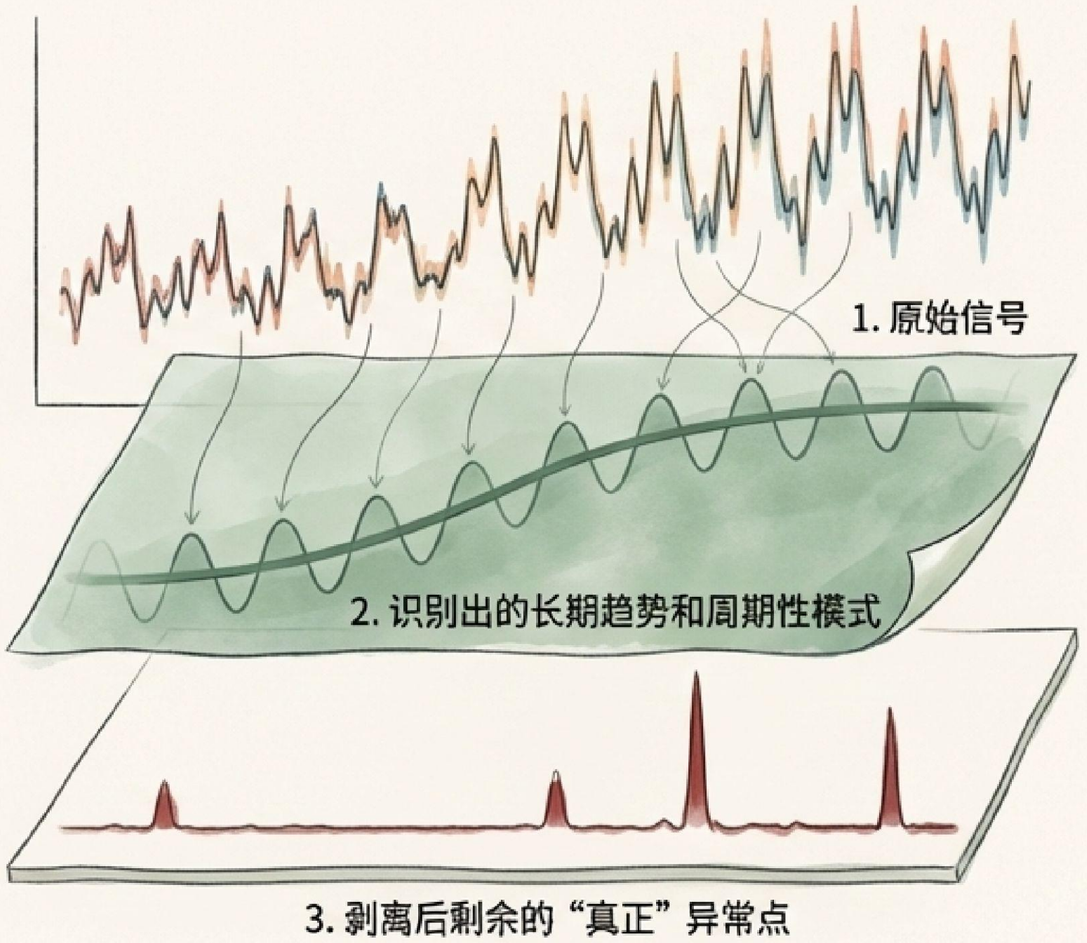
Elastic 异常检测：让机器发现“不寻常”

- **核心原理：**无监督学习。机器自主学习数据的正常节律，无需预先标记数据。
- **应用场景：**时间序列数据。完美适用于日志、指标等随时间变化的数据。
- **核心价值：**自动识别预期行为之外的偏差，从海量数据中发现信号。



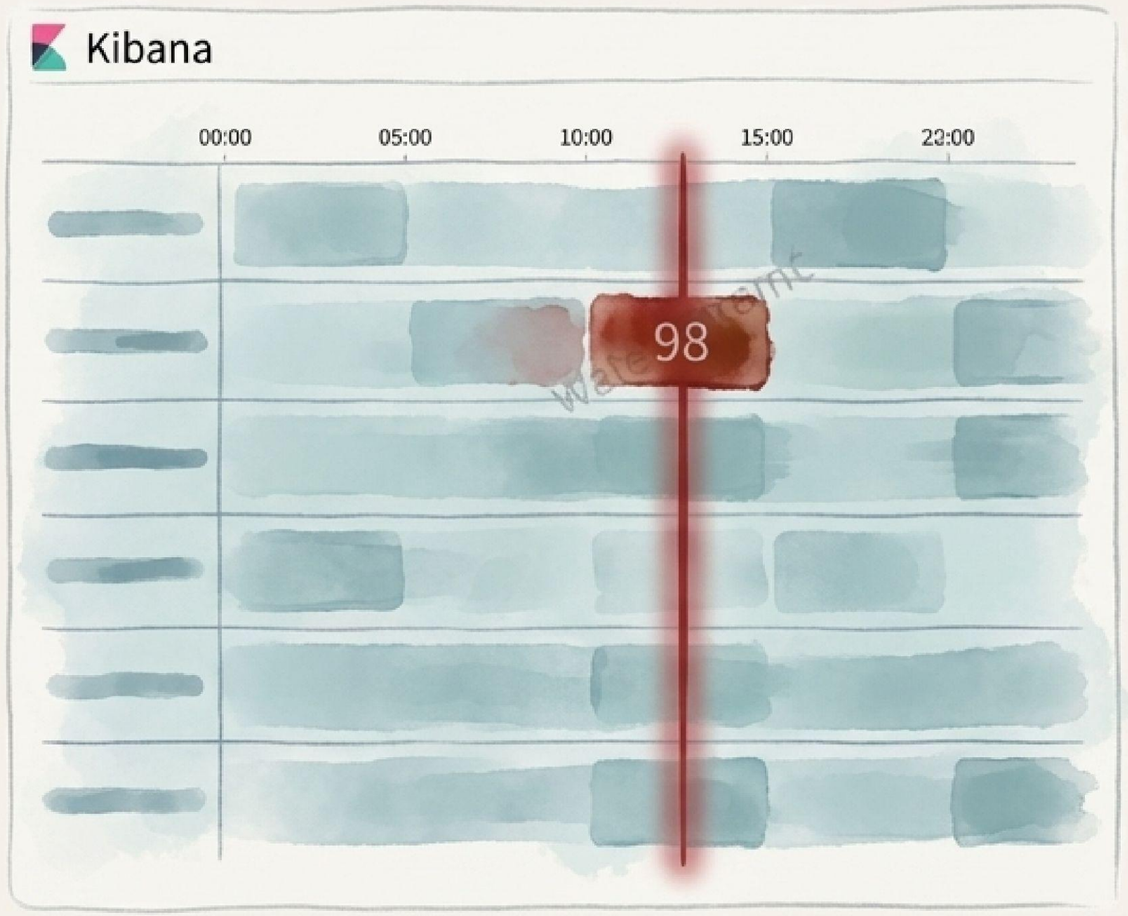
洞察背后的科学

- **概率建模**（Probabilistic Modeling）：基于历史数据创建概率模型，预测在任何给定时间点的可能值范围。
- **周期性与趋势分解**（De-trending & Seasonality）：自动识别并剥离数据中可预测的模式（如每日流量高峰），以发现真正的异常。
- **异常评分**（Anomaly Scoring）：将“不寻常”的程度量化为0-100分，分数越高，越值得关注。

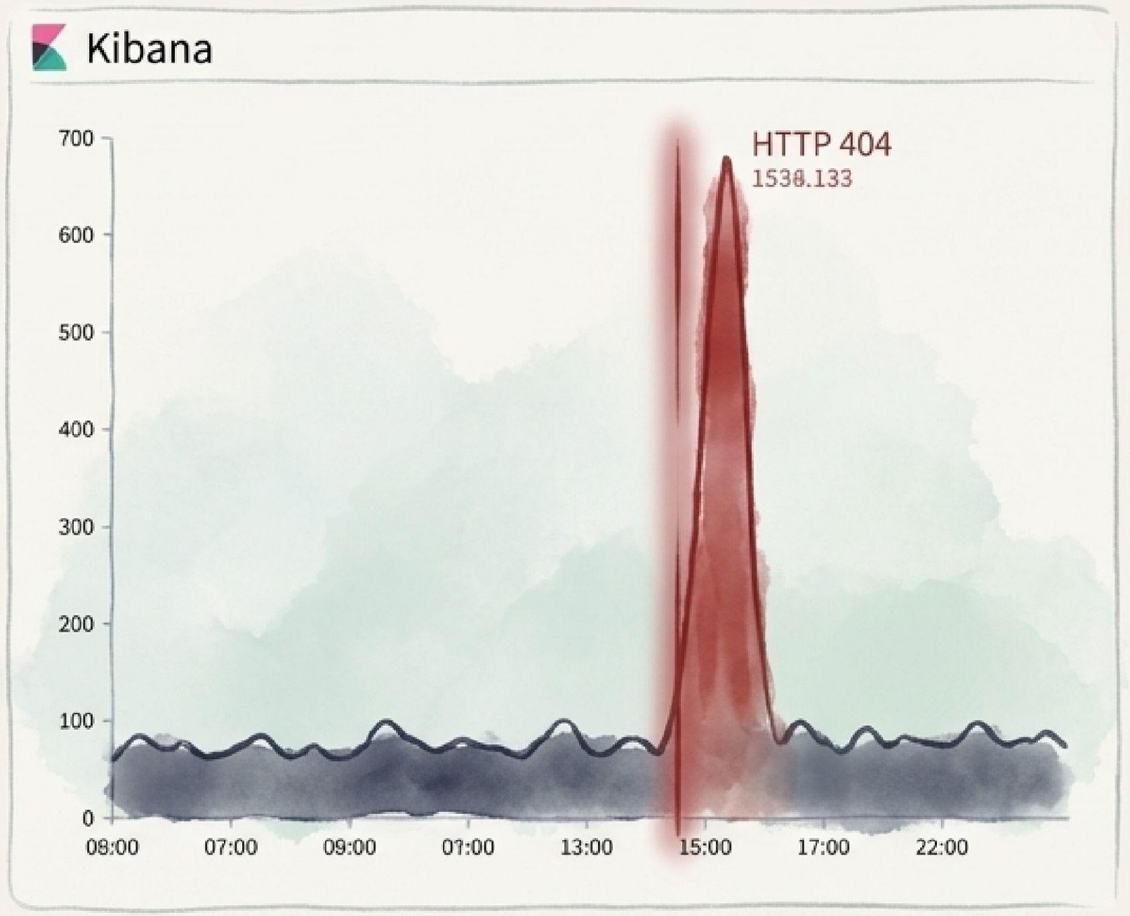


实战：Nginx 日志中的攻击预警

高分异常信号



响应码数量激增



旁注：这可能预示着一次暴力破解、目录扫描或API探测攻击。

超越时间序列：从“何时”到“何物”

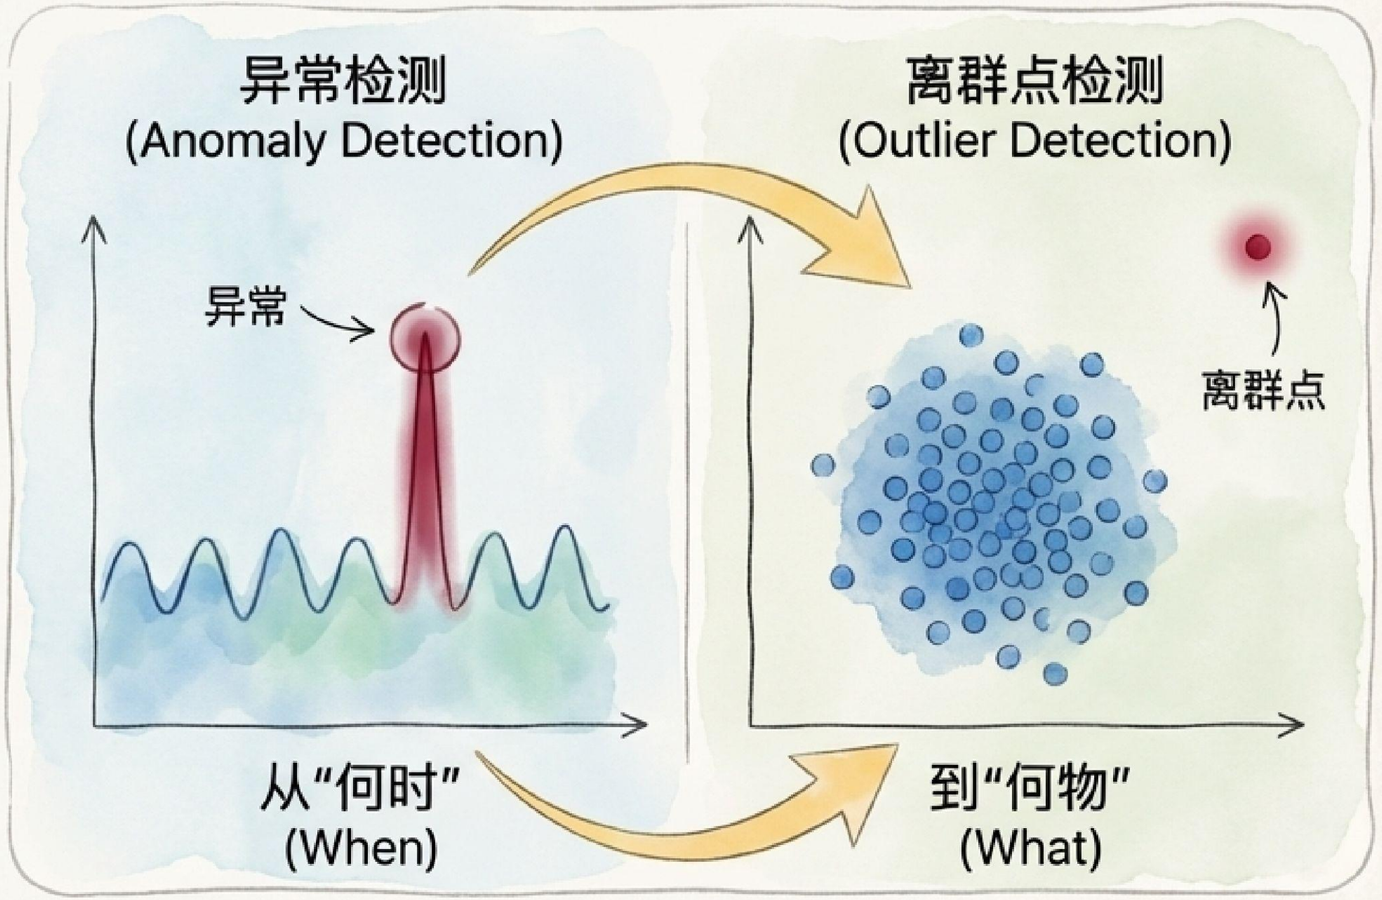
核心原理：以实体为中心（Entity-Centric）。分析对象的特征，而非仅仅是时间上的事件。

方法：支持无监督学习（离群点检测）和监督学习（分类、回归）。

关键区别：

异常（Anomaly）：一个时间点，其行为与自身的历史模式不符。

离群点（Outlier）：一个实体，其特征与群体中的其他成员不符。



数据帧分析 I：离群点检测（无监督）

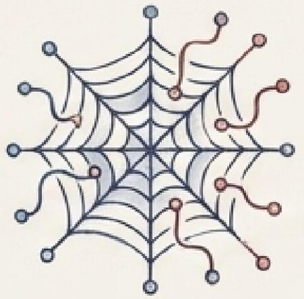
- **目标：**发现群体中的“害群之马”。
- **应用：**在刚才异常时间窗口内的所有访问中，哪个IP地址的行为模式最不寻常？

Kibana Data Frame Analytics results

ip_address	ml.outlier_score	sum(bytes)	distinct_count(url.keyword)
123.45.67.10	0.05	0.8GB	300
123.45.67.73	0.12	1.2GB	100
123.45.67.75	0.12	3.7GB	200
123.45.67.89	**0.99**	**5.2GB**	**4500**
123.45.67.80	0.12	3.9GB	500
123.45.67.91	0.12	2.6GB	100
123.45.67.82	0.05	1.6GB	70



传输了异常多的数据
(Transferred an abnormally high amount of data)

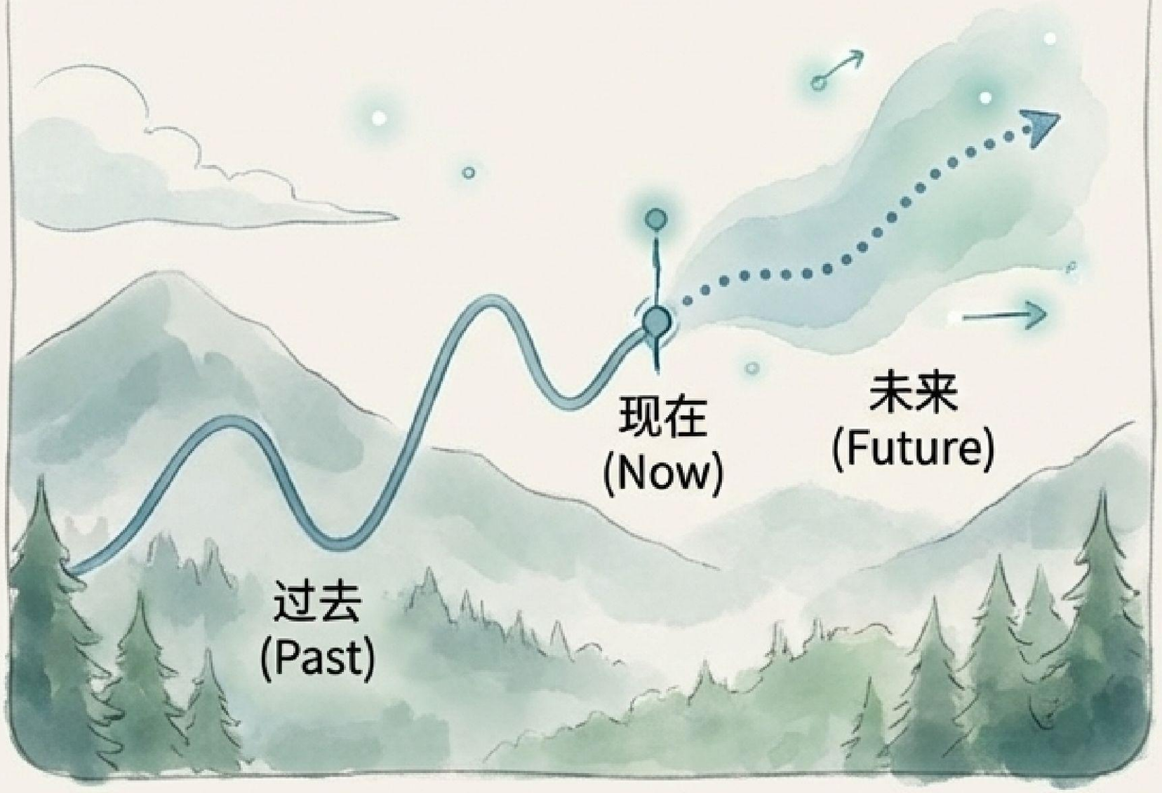


访问了远超常规数量的URL
(Accessed far more unique URLs than peers)

数据帧分析 II：预测与分类（有监督）

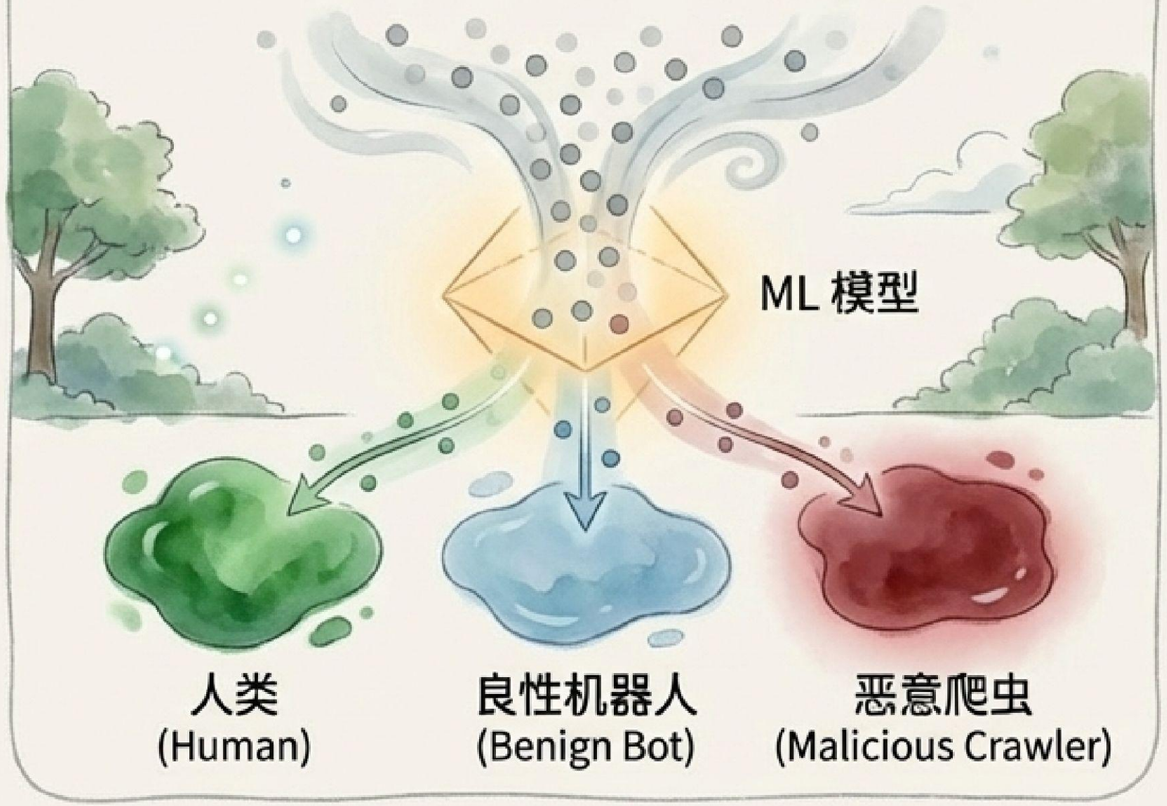
回归（Regression）：预测连续值

场景：根据当前流量模式和历史数据，预测下一小时的访问量，用于容量规划。



分类（Classification）：预测类别归属

场景：基于访问特征，自动将访问者标记为“人类”、“良性机器人”或“恶意爬虫”。

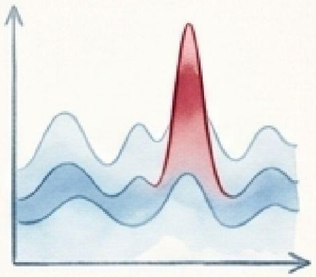


完整工作流：从信号到响应



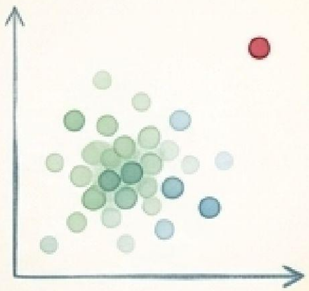
数据采集
(Data Ingestion)

Nginx Logs



实时异常检测
(Real-time Anomaly Detection)

发现流量异常！



离群点分析
(Outlier Analysis - DFA)

定位到恶意 IP / User-Agent



智能告警/响应
(Alerting/Response)

（Watcher）→ 自动创建安全工单 / 触发防火墙规则

智能洞察，运筹帷幄

自动化（Automation）：将专家经验沉淀为算法，从重复的、手动的分析工作中解放出来。

主动性（Proactivity）：从被动响应已知问题，转向主动预测未知风险与威胁狩猎。

深度（Depth）：获得超越传统仪表盘的、富有上下文的深度洞察，理解事件的“何时”、“何物”与“为何”。

