这句话，应该交给谁？

“把欢迎词翻译成日语，
然后让数字人播报。”

用一个业务请求，讲清决策接口、训练和校准

20页主讲，约25分钟；后附实现细节和阅读材料

用户要的是一整件事

把欢迎词翻译成日语，然后让数字人播报

只看前半句

翻译入口

可能只交出译文

只看后半句

数字人入口

可能直接等待播报稿

读完整句话

工作流入口

先翻译，再安排播报

“然后”告诉我们：前一步的结果，要交给后一步

选好入口，后面的任务才开始

决策模型回答

业务代码接着安排



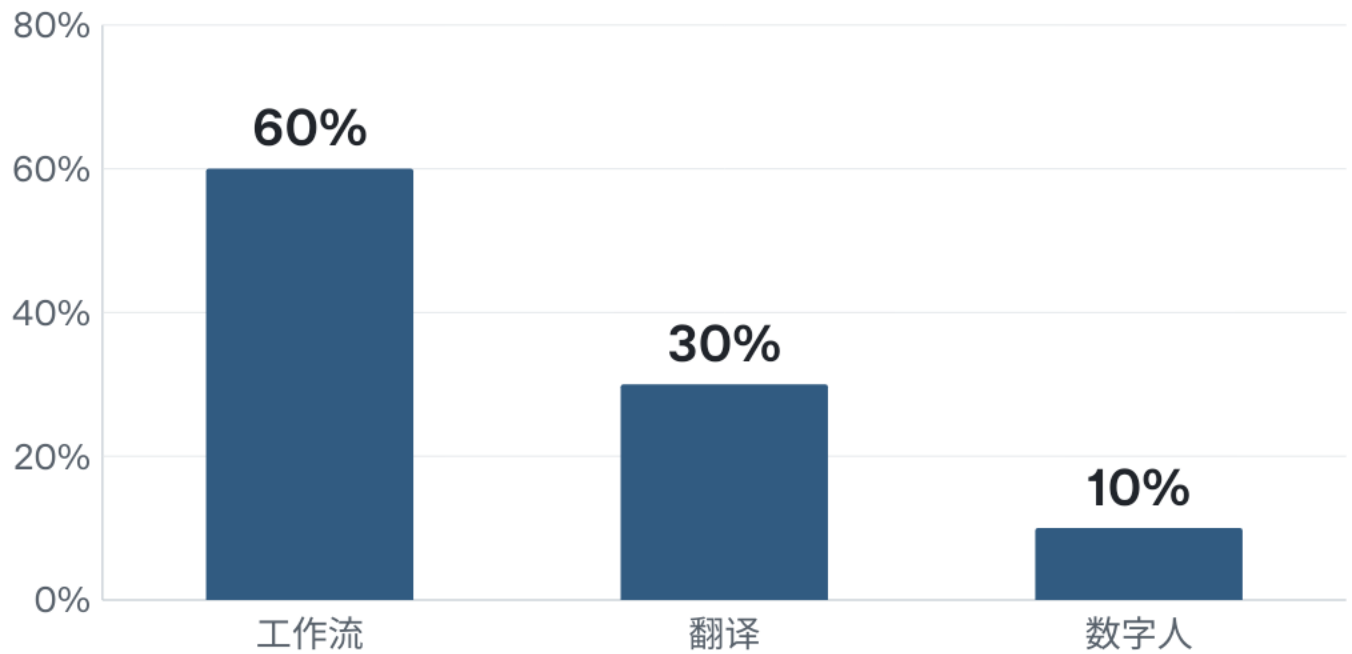
返回一个选项

拿到日语译文

把译文交给角色

权限、参数和执行结果，仍由原有流程检查

Choice 会返回选择和分数



choice：工作流

probabilities：
三个选项各有多少概率

confidence：0.40

按候选数调整后的最高分

API 的 confidence，不能直接读作“答对的概率”

3个候选的教学示意；这里的数值不是实测结果

一份译文，可以问不同的问题

原文：活动结束后，会员可领取退款。
译文：Members can receive a refund.

交给哪个处理入口？	Choice 选一个
有没有漏掉“活动结束后”？	**Noul 判断一个命题**
这句译文读起来自然吗？	Score 按有序等级打分

Choice / Noul / Score 是不同的提问方式；示例尚未运行

候选里没有正确入口，高分也帮不上忙

“推荐三部电影”

如果只给这三个选项

翻译

数字人

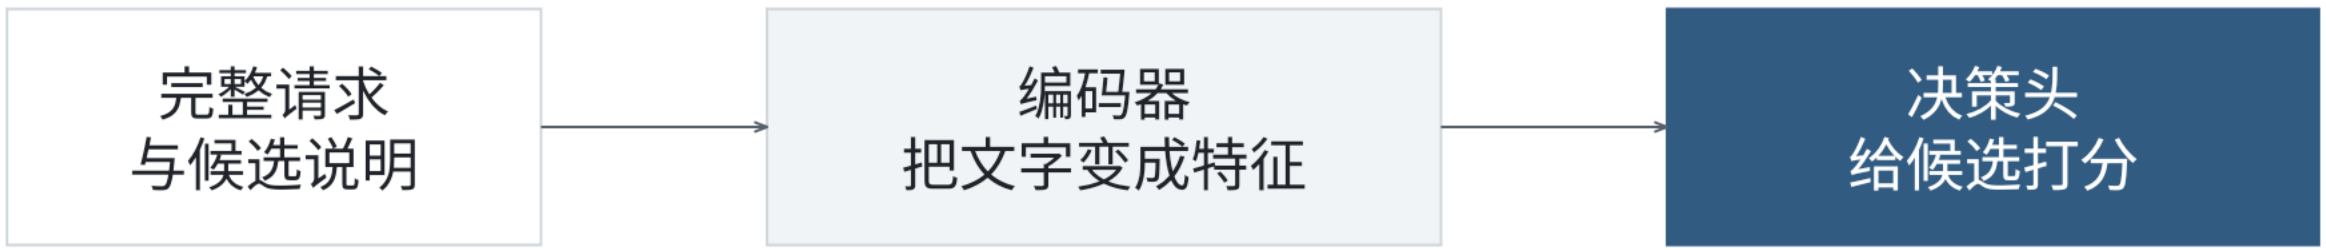
工作流

缺少一般问答入口

总会有一个最高分，
却可能根本不适合

范围外用 other 接住；入口不明用 clarify 追问

开源模型里，可以直接看到判断怎样算出来



看什么内容

怎样表示这句话

哪些选项更合适

Jev 已公开判断接口；完整网络和训练配方仍未公开

下图以本次使用的 Laya 为例；不代表 Jev 的内部结构

接 API 和自己训练，是两种使用方式

直接调用 Jev

在业务规则里写清问题和候选

使用官方托管服务
记录实际模型版本

官方目前不提供客户微调或 LoRA

用开源路线做业务训练

用自己的例子教模型分界线

本次实验：Laya
其他路线：PyTRIO 配方、Intern-Decision

需要自己验证数据、概率和运行环境

Head-only 和 LoRA，区别在训练哪里

Head-only

只训练最后的决策头



LoRA + 决策头

在编码器中加少量
可训练的适配参数



两种方法都看同一批带标签的例子，再比较实际结果

灰色保持不动；蓝色参与训练。图为本次训练范围的简化示意

练习、选版本、调分数、考试，各用一份数据

练习	选版本	调分数	考试
150条	50条	50条	50条
train	dev	calibration	test
用例子更新参数	比较每轮训练结果	只拟合温度 T	查看最终预测表现

同一句的改写和互译放在同组，避免跨份“见过近亲”

合成教学试点，AI 编写与复核，尚无人审；合计300条用于本轮四个划分

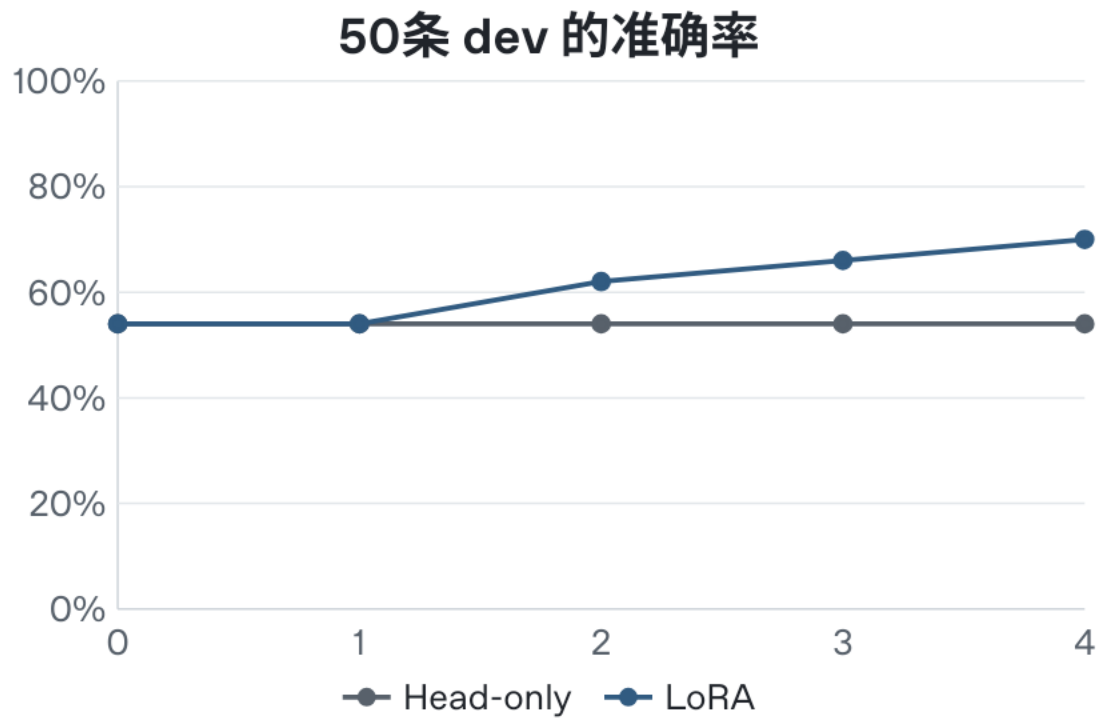
10题冒烟测试，先看接口能否走通

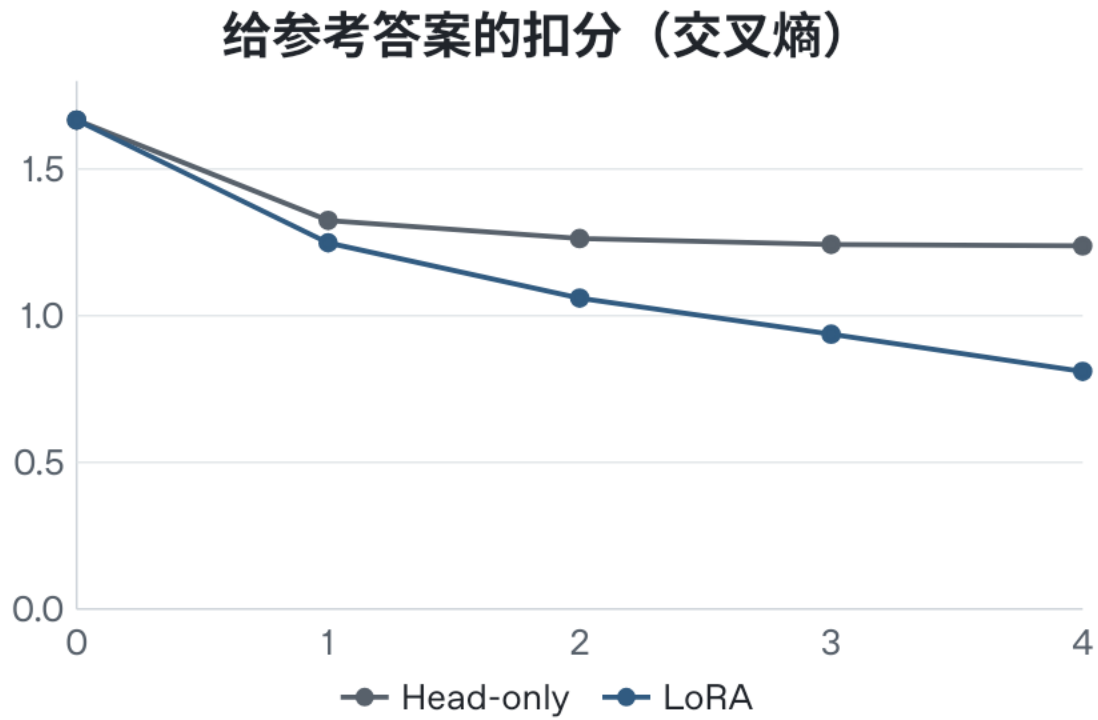
DeepSeek		9 / 10	生成五类概率 JSON
Laya		7 / 10	本地决策分布
Jev		8 / 10	托管 Choice 分布

同一道播报题，三个系统都选中了数字人入口

同一组10条合成样本的真实运行；蓝点命中参考标签；不能据此排出模型名次

LoRA 在开发集上多答对了8题





Head-only：27 / 50，始终未变

LoRA：27 / 50 变成 35 / 50

两种训练均为4轮、seed42；0代表训练前，1–4代表训练轮次

同一份50题，LoRA多答对11题

Head-only 24 / 50



48%

LoRA 35 / 50



70%

13题改对，2题改错，净增11题

50题合成测试集的逐题配对；每格一题，列为ID尾号001–010；蓝色正确，空心错误

最需要追问的10题，一题也没接住

本该先追问



0 / 10

实际选择了其他入口

- 数字人 1题
- 翻译 1题
- 工作流 4题
- 其他 4题

“按对方说的改一下”还缺少修改对象和对方要求

合成test中的真实预测；这10题的参考标签全部是 clarify

它只选了翻译入口，可能漏掉后半件事

把这份葡语问卷译成中文，
再导入问卷平台生成草稿。

参考任务

翻译问卷 → 导入平台，生成草稿

实际预测

translation

后一步可能被遗漏

LoRA给“翻译”98.49%的原始概率，仍选错入口

合成test中的真实错例：tutorial-test-agent_workflow-004；只展示预测及可能后果

报80%的那一组，应该约八成答对

不同请求的预测
最高选项概率都在80%左右

看这一组实际答对多少

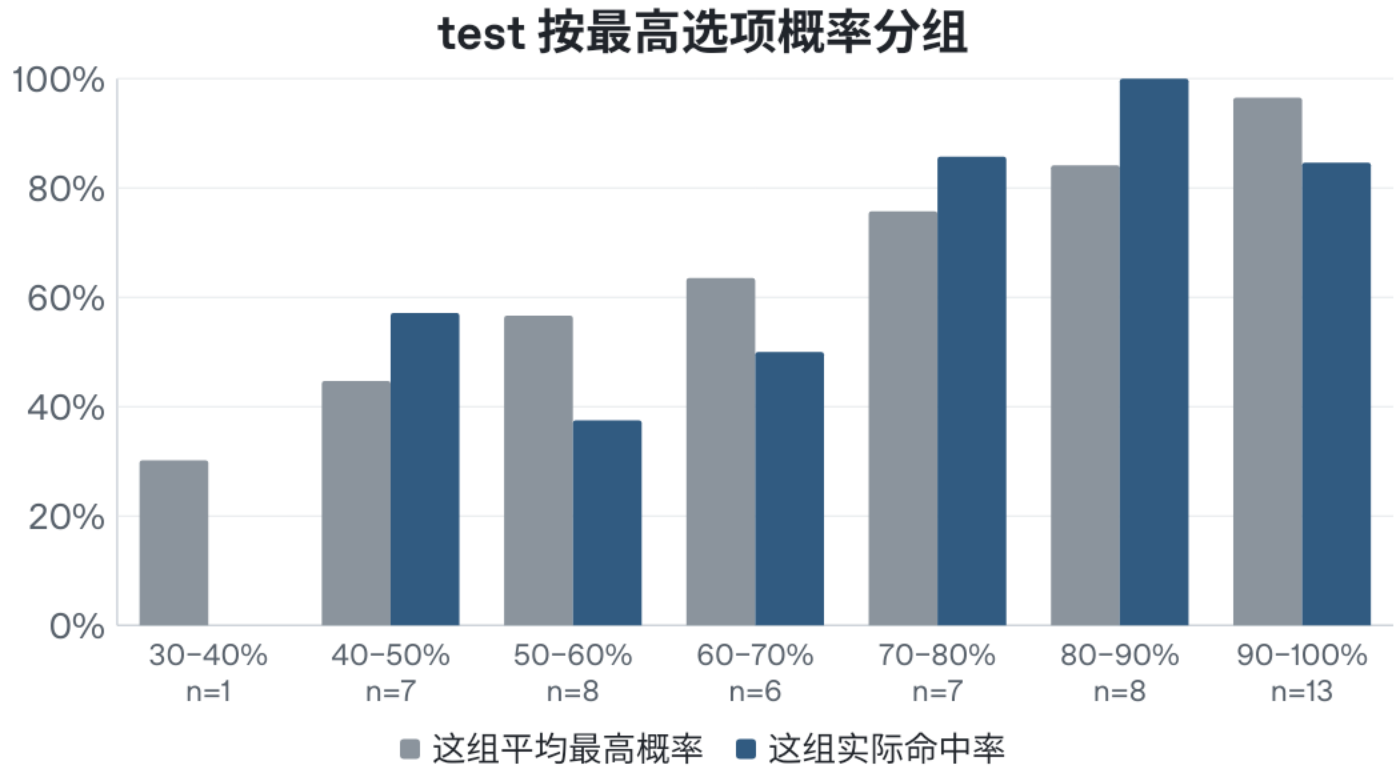


理想情况下，长期命中率接近80%

校准检查的是一组预测的频率，单条结果仍可能错

理想校准关系的教学示意；这些小点不是本次实验样本

调过分数后，50题的答案一个也没变



平均概率指标变好

下面三项越低越好

NLL .751 变成 .704

Brier .412 变成 .386

ECE .162 变成 .141

准确率仍是 35 / 50
选项顺序没有改变

温度校准调整概率的尖锐程度，不会补救选错入口

T=1.575只用50条合成 calibration 拟合；可配合短片②「概率变了，答案没变」

门槛都是90%，留下的错例没有减少

校准前

留下26题



错2题 / 接受26题

7.7%

校准后

留下13题



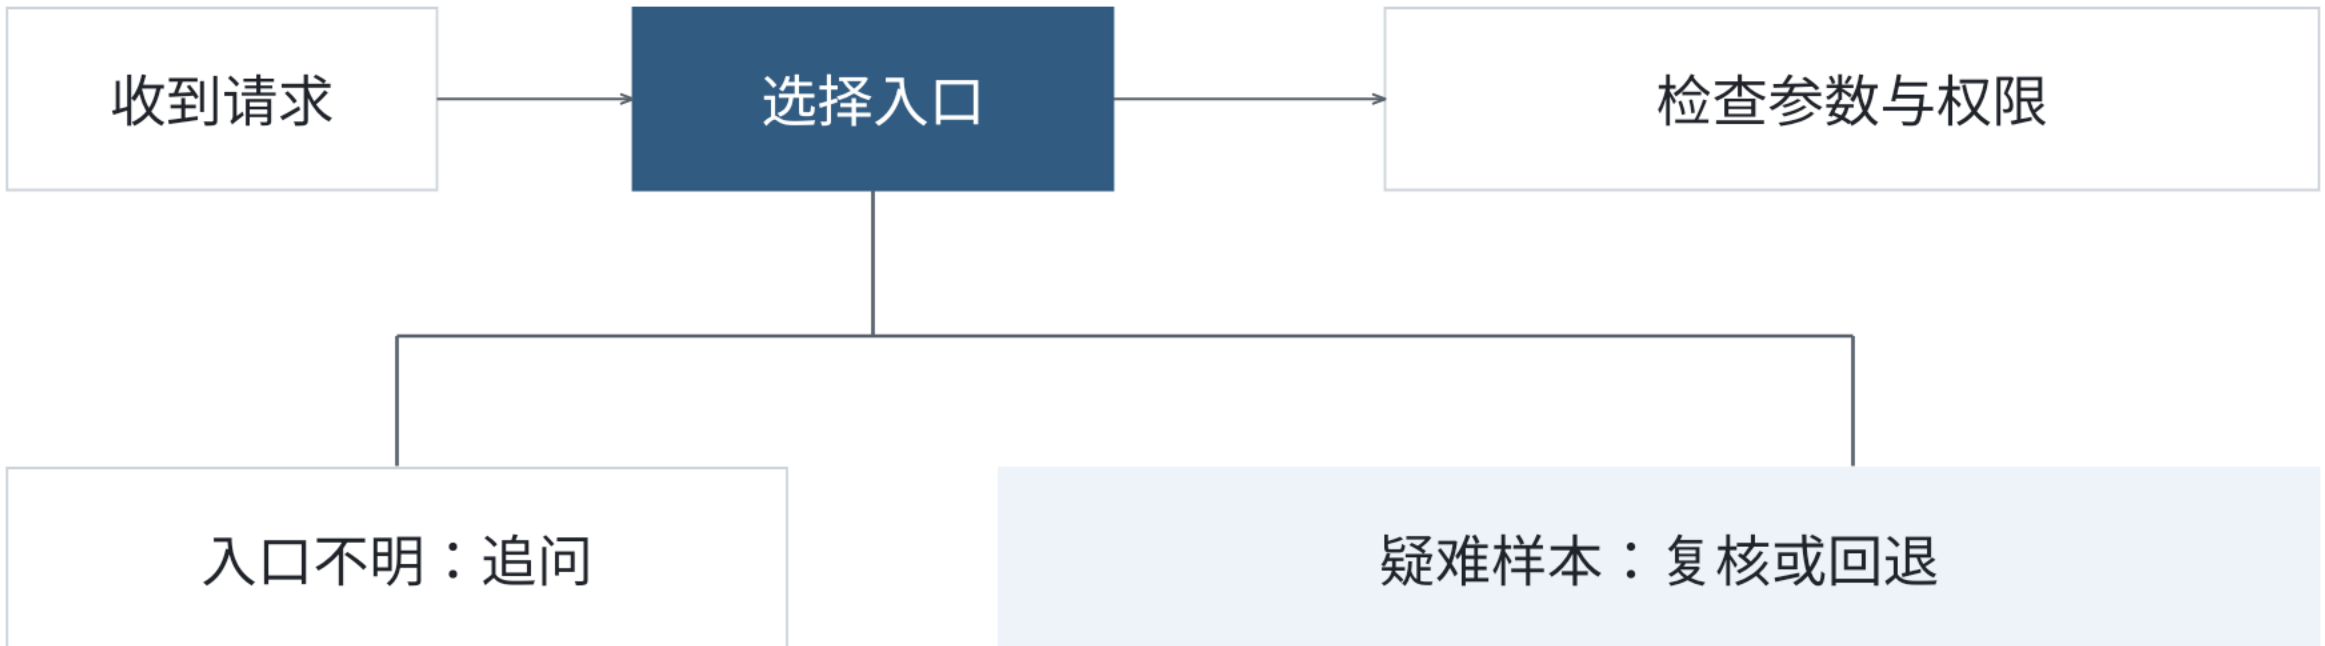
错2题 / 接受13题

15.4%

平均概率更好，不代表同一个门槛就更安全

50条合成test的事后探索：以最高选项概率≥0.90接受；没有冻结的生产门槛

上线前，还得跑通追问和回退



每次记录：原预测、补问或回退后的答案、是否真的纠错

下一步，让它跟着真实请求试跑

这次已经看到

24 / 50 变成 35 / 50

LoRA在这份合成test上多答对11题

但该追问的10题，仍然全错

下一轮要补的证据

真实请求，人工复核标签

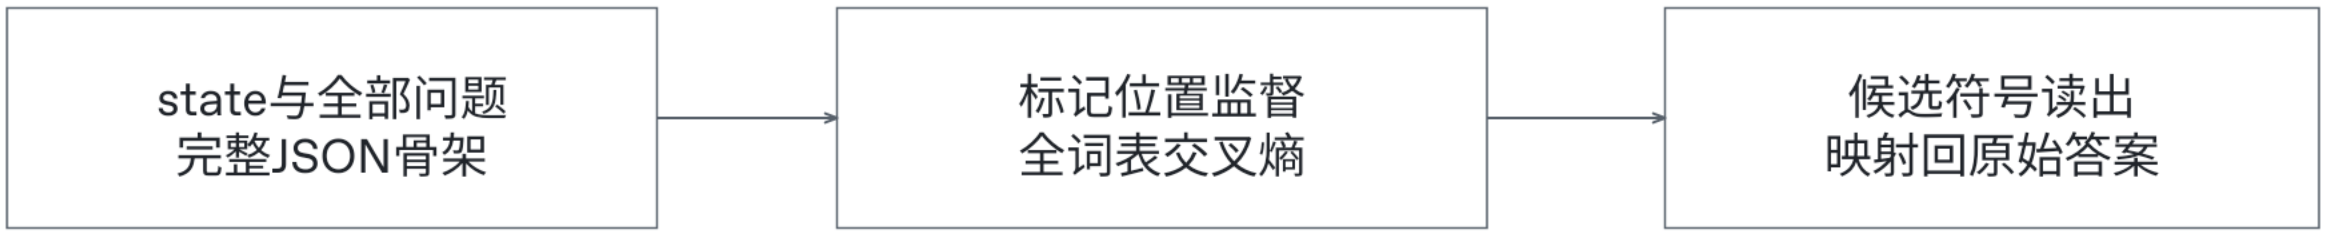
同一覆盖率下的关键错路由

追问、回退、延迟和总成本

先知道它会错在哪儿，再决定交给它多少自动处理

附录：PyTRIO 怎样把选择题变成训练样本

PyTRIO提供远程训练基础设施，社区配方使用Qwen3.5-4B LoRA SFT



公开的训练设置	实现与评估边界
2160条 / 2个epoch / rank32 / 270步	监督CE训练，未复现TypeSafe RLCD
标记前一位置监督，其余位置权重为0	top-k候选读出，缺失项近似填充
公开数据处理、训练、推理与校准代码	同工作流专用评测；本次未复跑

来源：agentic-rl-lab/09-pytrio-jev与PyTRIO文档；代码快照d2ba99c

附录：Intern-Decision 怎样读出答案

方面	已公开的实现	使用时应核对
基座与输入	Qwen3.5 0.8B / 2B / 4B 支持文本与图片	名称大小不是精确总参数数 默认决策长度8192 token
训练	冻结视觉与projector 训练语言骨干的标记位置CE	完整历史训练数据与混合细节未公开
推理	一次因果前向读取合法候选logits 输出Choice / Score / Noul	保持问题和选项顺序 记录backend与校准artifact
评测	作者提供多套任务结果与复现实验	准确率使用XTuner，延迟使用HF 不能直接当同硬件Jev速度比

可作为多模态决策扩展，在独立业务数据上评估后再决定采用

来源：InternLM/Intern-Decision README_zh-CN 源码与模型卡；本次未复跑

附录：来源与阅读路径

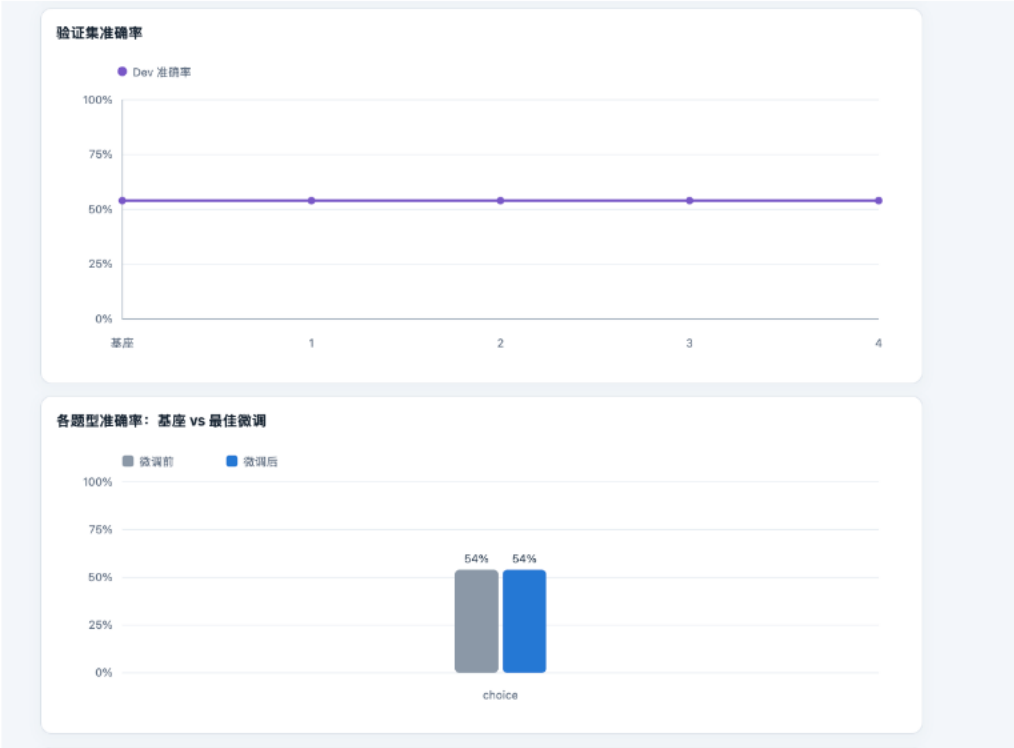
阅读目的	优先来源	使用边界
接口与公开限制	TypeSafe Introduction / Models / Jaggedness	作为产品契约和已披露限制
架构解释	Hume黑箱研究与开源实现源码	区分行为观察与架构假说
训练与复现	Jev Cookbook / PyTRIO社区配方 / Laya	核对实际损失、数据和读出代码
开放多模态路线	Intern-Decision中文README与评测协议	作者自报结果需独立业务复测
独立研究与应用	两篇Jev评测论文 / JevMade原项目	结论限定到模型、任务和运行设置

附录：实验记录与原始训练截图

证据	内容与当前页码
E01 / E02	10条smoke响应，第11页
E03 / E04	训练与test，第12–14页
E05 / E06	校准与错例，第15、17–18、31页

截图dev准确率始终54%，
与第12页重绘曲线一致

Head-only原始训练报告



附录：训练答案、调整概率，各自改了什么

阶段	更新对象	要回答的问题
监督训练 SFT / CE	权重或任务头	能否学到业务标签边界
温度校准	一个概率变换参数T	分布锐度能否匹配观察频率
阈值选择	接受、澄清或回退门槛	风险与覆盖率如何取舍
RLCD研究扩展	取决于奖励和具体实现	训练信号及泛化是否可验证

平台支持RL，不代表其中的CE训练配方已经使用RL

来源：Jev Cookbook、Laya模型卡、NanoJev与PyTRIO社区配方

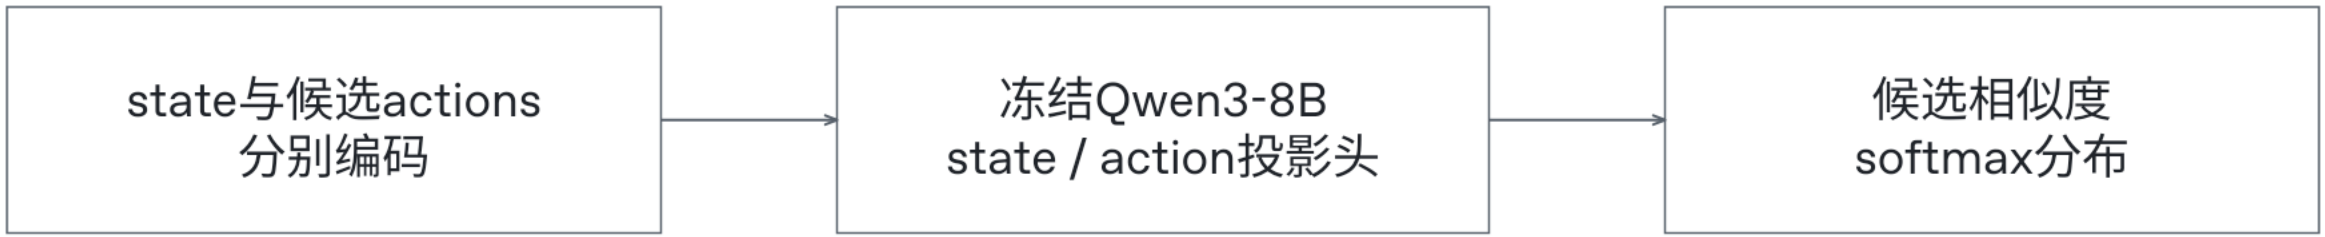
附录：接口相像，内部可以很不一样

项目	公开的实现方向	适合延伸的内容
Laya multilingual	mmBERT-base双向编码与候选打分 约322M	本地多语言决策与业务校准
NanoJev	Qwen3-0.6B加决策头	动态候选与公开训练流程
SemIf（原OpenJev）	冻结语言模型，读取候选logits	直接选项读出与校准
openJev-verdict-2.0	独立社区决策模型项目	核对具体权重与评测协议
layaMOE	共享冻结编码器、路由器、专用头	独立社区领域扩展，非官方Laya

同名confidence可能含义不同：Laya使用1−归一化熵，Jev Choice使用最大概率公式

附录：CLM-8B 用相似度给已有候选排序

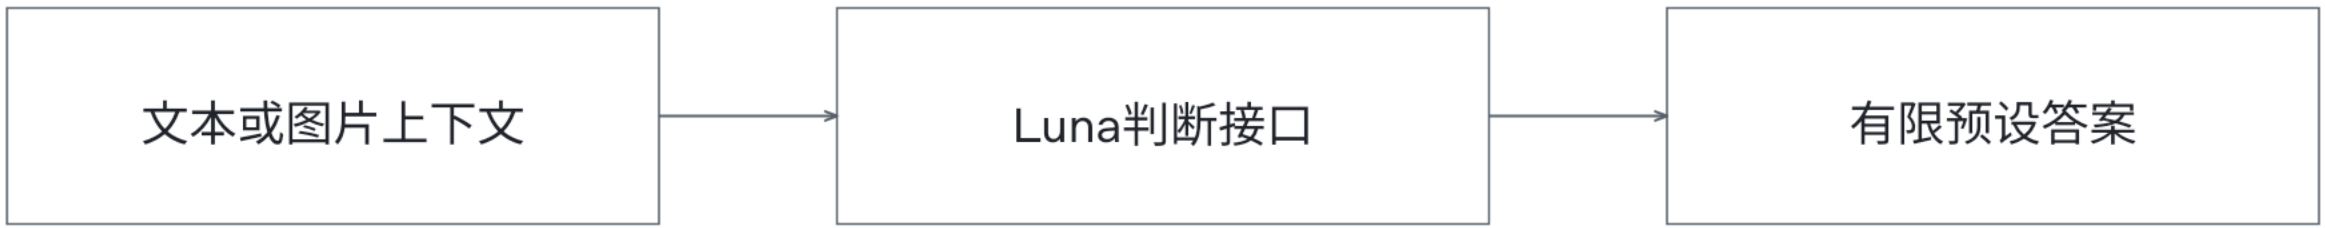
训练目标：双向InfoNCE



可解释的能力	必要的限制
为已有候选排序	不能补出缺失的正确动作
可针对任务训练投影头	公开verifier高分依赖任务微调
可迁移推理runtime	量化或backend变化后仍需复测与校准

来源：Contrastive-LM模型卡与仓库；概率相对于给定候选集合

附录：OpenAI Decisions API 的官方预览



采用前需要核对

账户权限、请求格式与价格、分数语义、业务准确率与延迟

来源：OpenAI DevDay 2026 Recap，2026-09-29；公告状态为有限预览

附录：路由、校准与拒答，分别读什么

研究方向	阅读问题	代表综述
模型路由与级联	调用前选择模型，还是先试再升级？	Moslem与Kelleher，2026 arXiv:2603.04445v3
分类概率校准	怎样检查和改善预测概率？	Silva Filho等，2021 / 2023 arXiv:2112.10327v2
拒答与交接	怎样定义不知道、停止与回退出口？	Wen等，2024 / 2025 arXiv:2407.18418

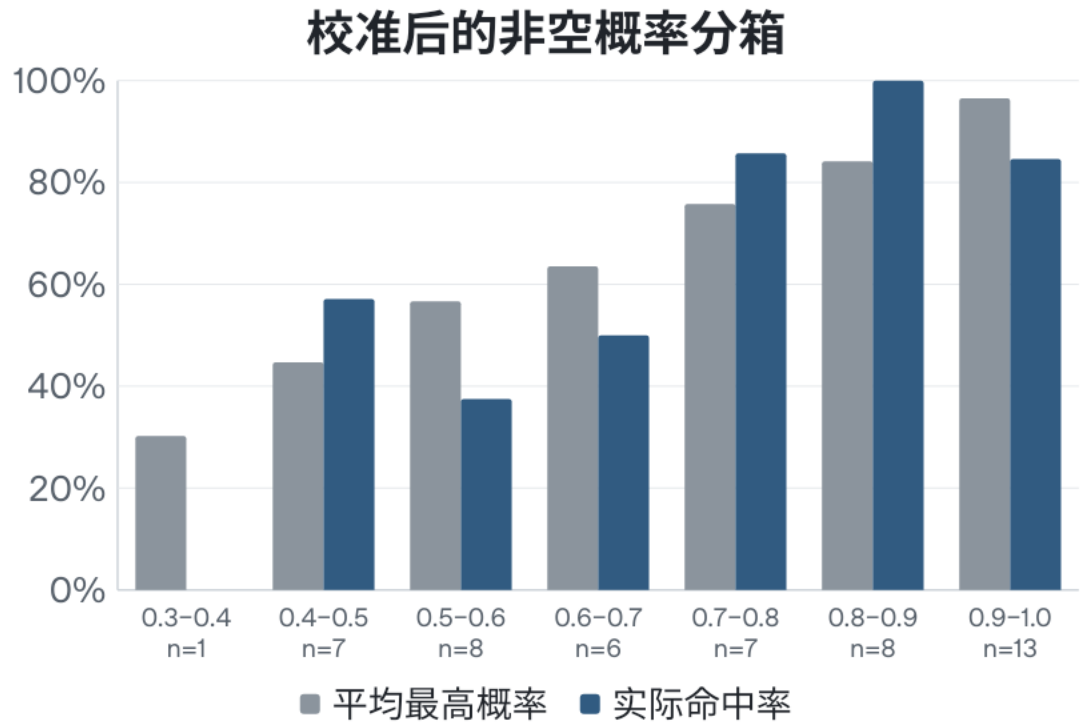
先统一概率与风险的定义，再比较不同接口和模型

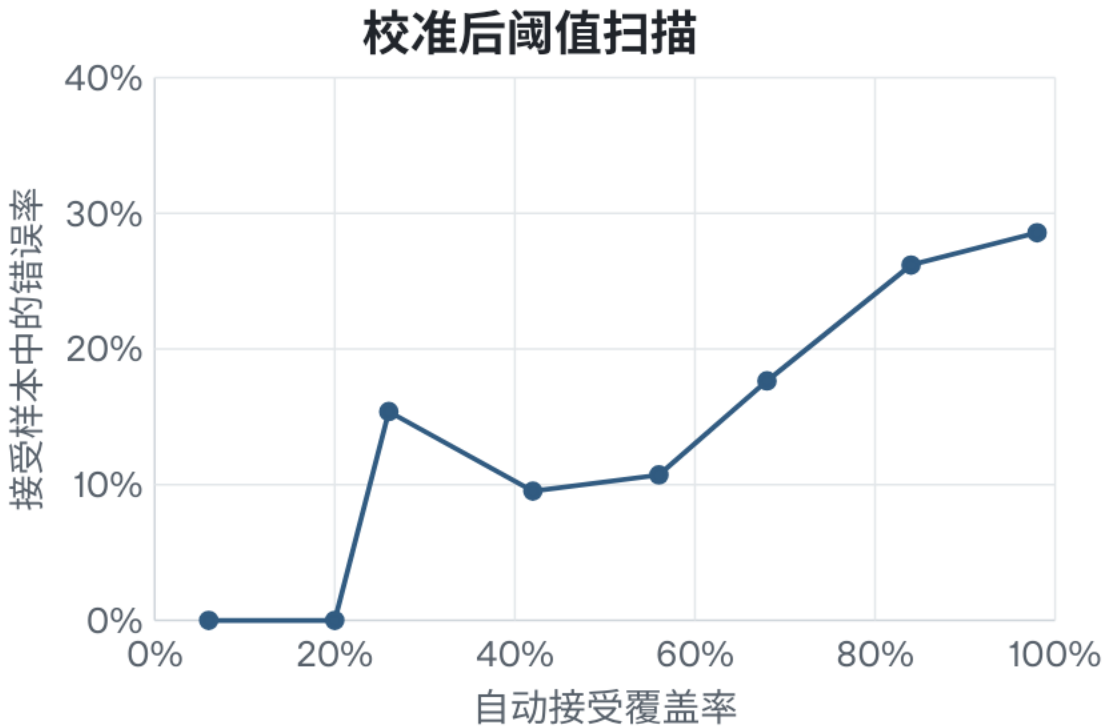
附录：独立评测提醒我们补哪些测试

研究	关注问题	对业务验证的启示
Deußer ·Sparrenberg ·Sifa 2026-09-29 arXiv:2609.37647v1	跨任务表现 二元概率阈值的任务差异	固定版本与同一数据 单独说明阈值选择方法
Rao与Callison-Burch 2026-09-28，v2 arXiv:2609.29769v2	rubric评审错例 首选与备用模型错误是否相关	逐样本比较回退纠错 同时记录回退引入的新错误

新的比较需统一数据、候选顺序、完整概率与运行条件

附录：校准可靠性与风险 / 覆盖率





阈值0.90：接受13/50，错2/13（15.4%）

阈值0.95的0/10错误不能作为部署保证；小样本风险曲线不必单调

E05；50条合成test，T=1.575仅由calibration拟合；以下阈值扫描为事后探索

参考资料：Jev 的官方接口

TypeSafe 官方文档；先弄清楚输入、候选与分数分别表示什么

01 **Introduction — TypeSafe AI**

Jev 的输入、三种问题原语、并行独立判断与代码组合方式。

02 **Models — TypeSafe AI**

核对模型版本、文本输入、上下文预算和服务规格；以访问日期为准。

03 **Choice — TypeSafe AI**

固定候选选择接口及完整候选概率；候选覆盖仍由调用者负责。

04 **Confidence — TypeSafe AI**

Choice 与 Score 的 confidence 计算规则；须与正确率概率及业务阈值区分。

参考资料：官方说明与能力边界

TypeSafe 公开说明及 OpenAI 官方预览公告；具体产品状态以原文为准

05 **2026 · Introducing System One Models & Jev**

TypeSafe 首发说明与 RLCD 命名；厂商报告不等于独立实验或架构披露。

06 **AI primer — TypeSafe AI**

官方对概率决策与训练目标的解释；未公开完整训练算法。

07 **Jev 1.13 jaggedness — TypeSafe AI**

官方能力边界和失效情形；用于补充候选顺序、上下文和精确运算测试。

08 **2026 · DevDay 2026 Recap**

Decisions API 的官方预览公告：有限答案、文本/图片上下文；不扩展到未披露性质。

参考资料：入门教程与外部解读

中文教程、工程文章与黑盒研究；架构猜测须与官方披露分开

09 **datawhalechina/jev-cookbook**

中文入门、问题原语、应用配方与本地训练示例；实现须按具体版本核对。

10 **2026 · What is Jev? TypeSafe's decision-making AI model and real benchmarks**

第三方入门与评测汇总；涉及指标时应回溯原始实验及其时间和协议。

11 **2026 · Jev Engineering 101**

用 LLM 决策模型与代码分工解释工程接入；性能数字为转述。

12 **2026 · Jev's Architecture Unmasked**

黑盒行为测试与架构假说；注意观测、推断和官方披露的证据层级。

参考资料：Laya 代码与模型卡

项目一手资料；通用模型、多语言模型和领域 checkpoint 分开看

13 **NandhaKishorM/laya**

Laya 的代码、接口、路由与部署资料；接口相似不表示复现 Jev 内部模型。

14 **convaiinnovations/laya**

英语 Laya 模型卡：ModernBERT 编码器与候选决策头。

15 **convaiinnovations/laya-multilingual**

多语言 Laya 模型卡：mmBERT 路线；预算与校准需按任务复测。

16 **convaiinnovations/laya-typed-decisions**

面向 typed-decisions 工作流微调的专用 checkpoint，区别于通用零样本设置。

参考资料：其他开源决策路线

不同作者的独立项目；名称或接口相似不代表底层架构相同

17 **vishalmysore/layaMOE**

独立社区扩展：共享冻结编码器、领域决策头与路由；小样本结果需谨慎解读。

18 **TianyuCodings/NanoJev**

公开的轻量决策头、动态候选与训练流水线；与 TypeSafe 私有架构区分。

19 **TheoLeeCJ/SemIf-OpenJev**

SemIf（原 OpenJev）探索开放模型直接候选读出；明确独立于 TypeSafe。

20 **Heman10x-NGU/openJev-verdict-2.0**

独立社区项目索引；同名 OpenJev 需注明 owner，榜单应核对协议。

参考资料：CLM 与本地运行

项目代码、原始模型卡与社区运行时；后端改变后仍需重新核对表现

21 **Contrastive-LM/CLM**

CLM 实现、推理与任务头微调；状态与候选动作分别编码。

22 **Contrastive-LM/CLM-v0.1-8B**

冻结 Qwen3-8B 加状态/动作投影头、双向 InfoNCE；概率相对于给定候选集。

23 **mlx-community/CLM-v0.1-8B-MLX-8bit**

Apple Silicon 的社区量化运行时移植；后端变化不等于独立质量提升。

参考资料：PyTRIO 与微调方法

平台文档、社区配方及 LoRA 论文；SFT 配方不能直接当作 Jev 的 RLCD

24 **PyTRIO：大模型后训练平台与 Training API**

后训练平台入口；平台支持 RL 不代表每个社区训练配方都使用 RL。

25 **Training — PyTRIO Docs**

官方训练 API：前后向计算、优化器更新和检查点等流程。

26 **agentic-rl-lab / 09-pytrio-jev**

agentic-rl-lab 的 PyTRIO 配方：masked CE、LoRA 与温度校准；作者结果非本实验复测。

27 **2021 / 2022 · LoRA: Low-Rank Adaptation of Large Language Models**

低秩权重更新的方法基础；用于区分任务头训练与 LoRA 适配。

参考资料：Intern-Decision 与结构化输出

项目一手资料和官方 API 文档；模型决策与输出格式约束分别阅读

28 **InternLM / Intern-Decision（中文 README）**

Qwen3.5 多模态结构化决策实现；训练、校准、评测与开放范围见中文说明。

29 **internlm/Intern-Decision-4B**

4B 模型卡与响应格式；作为待评估多模态扩展，不冒充本地已测基线。

30 **Structured model outputs**

OpenAI Structured Outputs 的 schema 接口文档；与 Decisions API 分别引用。

参考资料：路由、校准与拒答综述

相关研究方向的阅读地图；这些综述不专门介绍 Jev

31 **2026 · Dynamic Model Routing and Cascading for Efficient LLM Inference: A Survey**

区分请求前选模型的 routing 与先调用再升级的 cascading；非 Jev 专题综述。

32 **2021 / 2023 · Classifier Calibration: A survey on how to assess and improve predicted class probabilities**

分类概率的评估、后处理与训练期校准方法，直接关联 Choice 的概率解释。

33 **2024 / 2025 · Know Your Limits: A Survey of Abstention in Large Language Models**

拒答、选择性预测与风险—覆盖率框架；不能视为特定模型已具备的能力。

34 **2025 · Uncertainty Quantification and Confidence Calibration in Large Language Models: A Survey**

区分不确定性、置信分数与校准方法；用于拓展概率语义和评估设计。

参考资料：评测与答案核验

Jev 预印本、社区比较和早期 verifier 论文；外部结果不并入本次实验

35 **2026 · Evaluating and Benchmarking the System One Model Jev**

跨任务独立评测与概率阈值分析；结论限定于论文版本、数据及对照设置。

36 **2026 · JEV vs. LLMs as Rubric Judges: Cheaper, Faster, and Wrong in the Same Places**

rubric 评审与错误相关性研究；回退模型是否互补仍需业务逐样本验证。

37 **2026 · DDnim/jev-vs-laya**

小样本 SQL 审查、任务路由和领域微调案例；硬件与数据限制不支持普遍性能排名。

38 **2021 · Training Verifiers to Solve Math Word Problems**

生成多个解答并由 verifier 评分选择；为生成与判别分工提供历史背景。

参考资料：分类与对比学习的前身

原始论文；帮助判断哪些思想已有基础，哪些组合值得进一步验证

39 **2018 / 2019 · BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding**

双向 Transformer 预训练与分类微调基础，用于理解编码器决策路线。

40 **2019 · Benchmarking Zero-shot Text Classification: Datasets, Evaluation and Entailment Approach**

将标签描述转为文本蕴涵判断，连接 NLI 与零样本分类。

41 **2021 · Learning Transferable Visual Models From Natural Language Supervision**

CLIP 的图文对比学习与文本候选匹配，为相似度式决策提供背景。

42 **2025 · GLiClass: Generalist Lightweight Model for Sequence Classification Tasks**

轻量通用序列分类与单次前向候选判别，连接零样本分类生态。

参考资料：概率、校准与阈值

原始论文及 Google 官方课程；高分、正确率与业务放行阈值需要区分

43 **2017 · On Calibration of Modern Neural Networks**

温度缩放与神经网络置信校准；保持固定 logits 时不改变 argmax。

44 **2007 · Strictly Proper Scoring Rules, Prediction, and Estimation**

proper scoring rule 的概率预测基础；不据此推断 TypeSafe 私有 RLCD 损失。

45 **分类 — Google 机器学习速成课程**

分类概率、阈值及评估指标的中文入门课程。

46 **阈值和混淆矩阵 — Google 机器学习速成课程**

互动阈值教材：观察假正例、假负例和业务错误代价的变化。

参考资料：路由、图解与应用示例

论文、教学图解和社区 demo；演示不替代业务数据上的评测

47 **2024 / 2025 · RouteLLM: Learning to Route LLMs with Preference Data**

利用偏好数据学习强弱模型路由；质量、成本与迁移能力应共同评估。

48 **2018 · The Illustrated Transformer**

Jay Alammar 的可视化 Transformer 教程，用于注意力和编码/解码结构背景。

49 **Jev experiments — JevMade**

社区案例目录，可用来找应用点子；列表介绍需回到具体项目核对。

50 **browser-use/jev-ultrafast**

浏览器动作选择演示；演示效果不代替统一任务集上的评测。

51 **fhshaik/typesafe-mario**

从模拟器结构化状态选择游戏控制的演示，不是原始图像输入能力证明。